

Grundlagen der DS (INF2207 / CS264) (SoSe 26)

07.05.2026

Übung 4

4

Aufgabe 1 (Daten visualisieren). Laden Sie sich den `mushrooms.csv`-Datensatz mit Eigenschaften von essbaren und giftigen Pilzen von Moodle herunter. Erstellen Sie einen KNIME-Workflow zur Visualisierung der Daten.

Hinweis: Falls Fehlermeldungen auftreten, versuchen Sie diese selbstständig (z. B. mit einer Suchmaschine) zu beheben.

Mögliche Sinnvolle KNIME-Knoten für diese Aufgabe sind:

- Color Manager
- Bar Chart
- Scatter Plot
- 3D Scatter Plot (Plotly)

Können Sie anhand der Visualisierungen erkennen, welche Merkmale stark mit der Giftigkeit eines Pilzes zusammenhängen?

Aufgabe 2 (Decision Tree). Erstellen Sie mit KNIME einen Workflow, um für den obigen Datensatz einen Entscheidungsbaum zu trainieren und auszuwerten.

Sinnvolle KNIME-Knoten für diese Aufgabe sind:

- Partitioning
- Decision Tree Learner
- Decision Tree Predictor
- Scorer
- Decision Tree View

Beschreiben Sie kurz die Funktion der verwendeten Knoten und erläutern Sie die wichtigsten Einstellungen (z. B. Aufteilung in Trainings- und Testdaten, Zielvariable, Baumtiefe).

Wie gut ist das Modell auf den Testdaten? Welche Merkmale spielen im Entscheidungsbaum eine besonders wichtige Rolle?

Aufgabe 3 (Daten aufbereiten und klassifizieren). Laden Sie sich den `transaction_fraud.csv`-Datensatz mit normalen und verdächtigen Transaktionen von Moodle herunter.

Erstellen Sie einen KNIME-Workflow zur Aufbereitung der Daten. Löschen Sie keine Zeilen, sondern behandeln Sie fehlende oder ungeeignete Werte so, dass sie von einem Klassifikationsalgorithmus verarbeitet werden können.

Führen Sie danach eine Klassifikation mit einem Decision Tree durch.

Aufgabe 4 (Random Forest und Vergleich). Wenden Sie nun einen Random Forest auf den obigen Datensatz (`transaction_fraud.csv`) an, um eine Klassifikation zu erhalten.

Sinnvolle KNIME-Knoten hierfür sind:

- Random Forest Learner
- Random Forest Predictor
- Scorer

Vergleichen Sie die Ergebnisse mit dem zuvor trainierten Decision Tree. Gehen Sie dabei insbesondere auf folgende Punkte ein:

- Genauigkeit und Fehlklassifikationen
- Robustheit gegenüber Ausreißern und Rauschen
- Interpretierbarkeit der Modelle

Diskutieren Sie anschließend: Welche Methode (Decision Tree oder Random Forest) würden Sie in praktischen Anwendungen bevorzugen und warum?

Beziehen Sie in Ihre Antwort auch den `mushrooms.csv`-Datensatz mit ein: Welche Methode erscheint dort sinnvoller und weshalb?

Studentische Präsentationen: 21.05.2026