

Grundlagen der DS (INF2207 / CS264) (SoSe 26)

21.05.2026 Projekt 1: KI zum Verstehen von Texten

7

In diesem Projekt geht es um die automatische Analyse wissenschaftlicher Arbeiten mithilfe von Natural Language Processing und BERT-basierten Modellen. Das System soll wissenschaftliche PDFs in Text umwandeln, Research Questions erkennen, relevante Textstellen zu den jeweiligen RQs identifizieren und die Qualität der Antworten bewerten. Das Projekt kombiniert semantische Suche, Textklassifikation und praktische Machine-Learning-Pipelines. Für dieses Projekt ist es nötig, dass Sie Zugriff auf einen Rechner mit leistungsstarker NVIDIA-Grafikkarte haben. (Einen solchen Zugang können Sie im Rahmen der Veranstaltung im JupyterLab bekommen.)

Aufgabe 1 (Datensatzaufbau & Annotation). Erstellen Sie einen Trainingsdatensatz für die Erkennung von Research Questions sowie die Zuordnung von Textabschnitten zu Research Questions. Jedes Gruppenmitglied annotiert **20 Paper** aus anerkannten Zeitschriften wie Elsevier oder Springer, die höchstens 5 Jahre alt sind und fachlich wie folgt verteilt sein müssen. **Es dürfen keine doppelten Paper vorhanden sein.**

Fachgebiet	Anteil
Informatik	40 %
Wirtschaftsinformatik	30 %
Biologie	10 %
Medizin	10 %
Physik	10 %

Schritt 1 – PDF $\rightarrow$ Text: Laden Sie das Python-Script zum Umwandeln von PDF-Dateien in ein JSON-Format aus dem Moodlekurs herunter.

Schritt 2 – Annotation in Label Studio: Annotieren Sie die Texte mithilfe von [Label Studio](#). Einen Registrierungslink sowie ein Beispielprojekt erhalten Sie nach der Projektwahl per Mail. Markieren Sie alle expliziten Research

Questions und Hypothesen möglichst vollständig und semantisch korrekt; annotieren Sie ggf. mehrere RQs pro Paper. Bei mehreren aufeinander folgenden Questions oder Hypothesen, setzen Sie jeweils ein eigenes Label. Markieren Sie anschließend im Schlussteil des Papers die Textstellen, welche explizit auf die Beantwortung der Fragen oder Hypothesen eingehen.

Aufgabe 2 (BERT-Modelle). Lesen Sie die Dokumentationen zu den Modellen [BERT](#), [SciBERT](#) und [RoBERTa](#). Schauen Sie sich jeweils die Beispiele an, und versuchen Sie diese im JupyterLab oder auf der eigenen Hardware auszuführen. Modifizieren Sie diese anschließend ein wenig, und erklären Sie die Funktionsweise und Nutzung anhand Ihrer Modifizierungen.

Aufgabe 3 (BERT-Modell zur Research-Question-Erkennung). Trainieren Sie ein BERT-basiertes Modell zur Token-Klassifikation, das in gegebenen Texten eine oder mehrere Research Questions erkennt. Verwenden Sie hierfür geeignete Token-Labeling-Schemata wie beispielsweise BIO (Begin, Inside, Outside) oder BIOES/BILOU (Begin, Inside, Outside, End, Single). Das Modell soll unterschiedliche sprachliche Formulierungen von Research Questions robust generalisieren und möglichst domänenübergreifend einsetzbar sein.

Evaluieren Sie mindestens zwei unterschiedliche Token-Labeling-Schemata und vergleichen Sie deren Ergebnisse hinsichtlich Erkennungsleistung.

Aufgabe 4 (BERT-Modell erweitern). Erweitern Sie Ihr Modell aus der vorherigen Aufgabe um die zusätzliche Erkennung von Hypothesen. Ergänzen Sie hierzu das bestehende Token-Labeling-Schema um geeignete Subtypen, beispielsweise:

- B-HYP (Begin Hypothese), I-HYP (Inside Hypothese) sowie
- B-RQ (Begin Research Question), I-RQ (Inside Research Question)

Das erweiterte Modell soll sowohl Research Questions als auch Hypothesen innerhalb eines Textes zuverlässig identifizieren und voneinander unterscheiden können.

Aufgabe 5 (Vergleich mit bekannten Cloud-Systemen). Vergleichen Sie Ihre Lösungen mit den Lösungen, die Ihnen Cloud-Systeme wie ChatGPT, Mistral, etc. bei passenden Prompts liefern. Erklären Sie, warum Sie Ihre Prompts so definiert haben, wie Sie die Prompts definiert haben.

Aufgabe 6 (Benchmark verschiedener BERT-Modelle). Vergleichen Sie Ihre Modelle aus Aufgabe 4 und 5 auf realen Seminararbeiten, die von Ihren Gruppenmitgliedern oder befreundeten Kommilitonen erstellt wurden. Vergleichen Sie Accuracy und Laufzeit sowie die Generalisierbarkeit der Modelle zwischen den Fachgebieten. Wie können Sie die getroffenen Entscheidungen Ihrer BERT-Modelle mit XAI erklären?

Von den nachfolgenden Aufgaben brauchen Sie nur $x - 3$ viele zu lösen, wobei x die Anzahl Gruppenmitglieder ist.

Aufgabe 7 (Modell zur Research-Question-Relevanzbewertung). Verwenden Sie ein bestehendes Embedding-Modell (z. B. [Sentence-BERT](#)), um Research Questions und Textsegmente semantisch zu vergleichen. Es sollen ausschließlich bestehende Modelle verwendet und keine eigenen Modelle trainiert werden.

Zerlegen Sie die wissenschaftliche Texte in Sätze oder kurze Absätze und entwickeln Sie eine Strategie (z. B. Top- k , Threshold oder Kombinationen), um relevante Textsegmente zu den jeweiligen Research Questions zu finden. Evaluieren Sie Ihre Ergebnisse und diskutieren Sie über mögliche Erweiterungen.

Aufgabe 8 (Erweiterung des Testdatensatzes). Vergrößern Sie Ihren Testdatensatz mithilfe eines Large Language Models (z. B. GPT-4, Llama oder Mistral). Erweitern Sie dazu den bestehenden Datensatz um synthetisch generierte Testdaten mit unterschiedlichen Strukturen. Generieren Sie insbesondere Beispiele mit klar formulierten Forschungsfragen und Hypothesen, aber auch Beispiele ohne Forschungsfragen, ohne Hypothesen oder ohne explizite Verweise auf Forschungsfragen.

Untersuchen Sie anschließend, wie sich die Erweiterung des Datensatzes auf die bisherigen Ergebnisse auswirkt. Analysieren Sie dabei insbesondere, ob sich bestehende Kennzahlen oder Bewertungen verändern und ob Forschungsfragen, Hypothesen und Antworten nun zuverlässiger erkannt werden.

Hinweis: Erläutern Sie in Ihrer Präsentation und Dokumentation die Architektur des Gesamtsystems, die Qualität der erstellten Annotationen und wie die Modelle evaluiert wurden. Beschreiben Sie aufgetretene Herausforderungen und Limitationen und stellen Sie Beispiele für Modellvorhersagen vor. Erstellen Sie Screenshots von mehreren Probelaufen Ihrer Anwendung.

Abgabe:

Dokumentation und Realisierung: 06.07.2026

Präsentation: Am Tag der Präsentation bis 23.59 Uhr