

Grundlagen der DS (INF2207 / CS264) (SoSe 26)

21.05.2026 Projekt 3: Umsatzprognose mit Knime

9

In diesem Projekt sollen Sie Daten einer Einzelhandelskette mit Hilfe von Knime analysieren. Nur was in Knime nicht möglich ist, kann mit einem Python-Knoten in Knime realisiert werden. Ziel ist es, aus historischen Filialdaten eine Prognose für zukünftige Umsätze zu erstellen.

Dazu müssen die bereitgestellten Daten zunächst untersucht, bereinigt und geeignet aufbereitet werden. Anschließend sollen die vorbereiteten Daten in ein Regressionsmodell überführt werden, mit dem sich die Umsätze der Filialen vorhersagen lassen.

Aufgabe 1 (Datensätze begutachten). Schauen Sie sich die bereitgestellten Datensätze an:

- `filialumsatz.csv`
- `filialen.csv`

Machen Sie sich mit den Daten vertraut. Untersuchen Sie, welche Informationen in den Tabellen enthalten sind, welche Spalten zusammengehören und welche Größe der Datensatz hat.

Aufgabe 2 (DQ-Maßnahmen für die Filialdaten). Bereinigen Sie die Daten in Knime. Nicht alle Werte sind eindeutig rekonstruierbar. Entscheiden Sie selbst, welche Daten Sie wie korrigieren, entfernen oder unverändert übernehmen. *Hinweis:* Achten Sie auf fehlerhafte, fehlende oder unplausible Einträge. Manche Fehler ergeben sich nur, wenn Sie beide Datensätze gleichzeitig betrachten.

Aufgabe 3 (DQ-Kennzahlen für die Filialdaten). Nachdem die Daten bereinigt wurden, berechnen Sie mehrere aussagekräftige Datenqualitätskennzahlen, um die Schwachstellen im ursprünglichen Datensatz zu beschreiben. Mehr Details hierzu finden Sie unter anderem in Kapitel 3 von <https://link.springer.com/book/10.1007/978-3-658-47317-4> nachdem Sie sich über „Log in via an institution“, dann THM eingeloggt haben.

Vergleichen Sie dabei nach Möglichkeit den Zustand vor und nach der Bereinigung. Die Kennzahlen sollen zeigen, welche Probleme im Datensatz vorhanden waren und wie stark diese durch Ihre Aufbereitung reduziert wurden. *Hinweis:* Ggf. noch mal Aufgabe 2 überarbeiten.

Aufgabe 4 (XGBoost-Verfahren). Schauen Sie sich die offizielle Erklärung [Introduction to Boosted Trees](#) der XGBoost-Dokumentation sowie das KNIME-Beispiel [Housing Value Regression with XGBoost](#) an. Verstehen Sie die Idee hinter dem Verfahren und analysieren Sie dessen Ergebnisse. Wann eignet es sich, dieses Verfahren einzusetzen?

Aufgabe 5 (Umsatzprognose mit XGBoost). Verwenden Sie XGBoost, um den Umsatz der Filialen vorherzusagen. Passen Sie die Daten so an, dass sie für ein Regressionsmodell verwendet werden können. Berücksichtigen Sie dabei sowohl zeitliche Informationen als auch geeignete Informationen über die Filialen. Teilen Sie die Daten sinnvoll in Trainings- und Testdaten auf. Begründen Sie kurz, warum Ihre Aufteilung für diesen Datensatz geeignet ist.

Aufgabe 6 (Auswertung und Visualisierung). Bewerten Sie das Modell aus der vorherigen Aufgabe mit passenden Metriken. Gehen Sie dabei insbesondere darauf ein, wie stark die Vorhersagen im Durchschnitt und in auffälligen Fällen vom tatsächlichen Umsatz abweichen. Gehen Sie insbesondere darauf ein, wie gut die Umsatzprognose funktioniert, wo größere Abweichungen auftreten und ob bestimmte Filialen oder Zeiträume schwieriger vorherzusagen sind als andere. Nutzen Sie XAI-Methoden, um die abhängige Variable Umsatz von den unabhängigen Variablen zu erklären.

Bauen Sie ein Dashboard, in dem Sie die wichtigsten Ergebnisse der Datenaufbereitung, Analyse und Modellbewertung darstellen. Verwenden Sie dafür geeignete KNIME-Knoten, zum Beispiel:

- Table View,
- Statistics View,
- Bar Chart,
- Line Plot,
- Scatter Plot,
- Histogram,
- Box Plot,
- Heatmap,
- Tile View oder
- Pie Chart

Von den nachfolgenden Aufgaben brauchen Sie nur $x - 3$ viele zu lösen, wobei x die Anzahl Gruppenmitglieder ist.

Aufgabe 7 (Filialen vergleichen und gruppieren). Untersuchen Sie, ob sich die Filialen anhand ihrer Umsatzverläufe und weiteren Merkmale in sinnvolle Gruppen einteilen lassen, insbesondere durch ein Clustering Verfahren. Vergleichen Sie diese Gruppen miteinander. Gehen Sie dabei insbesondere darauf ein, ob bestimmte Gruppen höhere Umsätze, stärkere Schwankungen oder andere auffällige Muster aufweisen.

Visualisieren Sie Ihre Gruppierung und die Unterschiede zwischen den Gruppen geeignet. Die Visualisierungen sollen nachvollziehbar zeigen, warum die gewählten Gruppen sinnvoll sind und wie sie sich voneinander unterscheiden. Beschreiben Sie, ob eine gemeinsame Umsatzprognose für alle Filialen sinnvoll ist oder ob für verschiedene Filialgruppen unterschiedliche Modelle geeigneter wären.

Aufgabe 8 (Was-wäre-wenn-Analyse). Führen Sie eine Was-wäre-wenn-Analyse auf Basis Ihres Vorhersagemodells durch. Untersuchen Sie dazu, wie sich die vorhergesagten Umsätze verändern, wenn einzelne Einflussgrößen, beispielsweise die Distanzen zu benachbarten Filialen oder die Anzahl an täglichen Kunden, gezielt verändert werden. Betrachten Sie dabei mehrere selbst gewählte Szenarien.

Stellen Sie die Ergebnisse der Szenarien übersichtlich grafisch dar. Die Visualisierung soll deutlich machen, wie stark sich die Vorhersagen in den verschiedenen Szenarien verändern. Erklären Sie, ob Ihre Ergebnisse plausibel sind.

Hinweis: Erläutern Sie in Ihrer Präsentation und Dokumentation, welche Daten Sie verwenden, wie Sie die Daten für die Analyse vorbereiten und wie Ihre Analyse durchgeführt wird. Erstellen Sie in Ihrer Dokumentation Screenshots von mehreren Analysen Ihrer Anwendung.

Abgabe:

Dokumentation und Reaisierung: 06.07.2026

Präsentation: Am Tag der Präsentation bis 23.59 Uhr